

XAI 기반 팜 공정 수율 유지 및 비용 최적화 시뮬레이터

프로젝트 최종 정리 (22라운드 반영)

이 문서 사용법

- 1~2장: 배경. AI/데이터 모르는 사람도 읽을 수 있게 씀
- 3장: 용어·수식 사전. 모르는 단어 나오면 여기로
- 4~7장: 파이프라인 단계별 상세
- 8장: 그림별 "축이 뭐고 뭘 읽어야 하나"
- 9~12장: 확정 숫자 / 철회 이력 / 한계 / 발표 서사
- 13장: 멘토링 질문 리스트

0. 한 줄 요약

우리는 더 좋은 모델을 만들지 않았다. 같은 모델로 더 나은 결정을 만들었다. 그리고 비용비를 모르는 현업에게 되묻는 대신 역산해준다. 나아가 이 도구는 "모델이 필요한지"까지 비용으로 판정한다.

	기존 AI 프로젝트	우리 프로젝트
목표	AUC 최대화	비용 최소화 의사결정
예측 점수의 역할	끝 (결과물)	입력 (그 위에 비용 계층)
산출물	"이 제품은 불량 확률 0.7"	"검사하라 / 하지 마라 / 모델 자체가 불필요하다"

1. 배경 — 왜 이 문제인가

1-1. 반도체·디스플레이는 전수 검사가 원칙이다

만든 걸 하나도 빠짐없이 전부 검사합니다.

왜? 불량 하나가 고객사로 흘러가면 손해가 제품값의 수백~수천 배이기 때문입니다.

- 세트 업체 라인 정지
- 리콜·손해배상
- 신뢰도 하락 → 수주 감소

자동차용 반도체는 관리 기준이 **DPPM 한 자릿수**(백만 개당 몇 개)입니다.

그런데 전수 검사는 비쌉니다.

$$\text{테스트 비용} = (\text{테스트 시간} \times \text{장비 시간당 효율}) \div \text{병렬도}$$

장비 감가상각이 비용의 대부분이라 **시간이 곧 돈**입니다. 그래서 업계는 계속 줄이려 합니다.

1-2. 두 가지 실수 — Overkill과 Underkill

용어	뜻	비용
Overkill (과검)	양품인데 불량으로 판정	덜짙한 제품 폐기
Underkill (미검)	불량인데 양품으로 판정	고객 유출 → 재앙

직관 — 공항 보안검색 검색을 엄격히 하면 위험물은 확실히 잡지만(Underkill↓) 덜짙한 승객이 계속 걸립니다(Overkill↑). 느슨하게 하면 반대. **둘을 동시에 줄일 수는 없습니다.** 어디서 균형을 잡을지만 정할 수 있습니다.

그리고 **비대칭**입니다:

- 과검 손실 = 제품 하나 값
- 미검 손실 = 제품값의 수십~수천 배

→ 실무는 **과검을 감수하고 미검을 죽이는 쪽**으로 기울어 있습니다.

추가로 중요한 비대칭: 과검은 **눈에 보이고**(폐기 수량으로 집계됨), 미검은 **안 보입니다**(고객 반품으로 뒤늦게 역추정). 그래서 조직이 무의식적으로 과검만 줄이는 쪽으로 흘러가기 쉽습니다.

1-3. 대부분의 AI 프로젝트가 멈추는 지점

"불량을 잘 예측하는 모델을 만들었다"까지가 보통입니다. 그런데 현장에 필요한 건 다릅니다:

1. 모델이 0.7점을 줬다. **그래서 검사할까 말까?** → 임계값이 필요한데, 그건 **비용이 정한다**
2. 비용비를 입력하라고? **우리 회사 미검 비용을 누가 아는데?**
3. 왜 불량이라는 건데? **어느 장비를 점검하라는 거야?**

이 세 질문에 답하는 것이 본 프로젝트입니다.

2. 데이터

주최측 제공 **SECOM** (반도체 공정 데이터).

항목	값
크기	1,567 run × 590 센서
불량	104건 (6.64%)
결측	4.54%
기간	2008-01-08 ~ 2008-12-10 (약 11개월)

⚠ **용어:** 흔히 "1,567 lot"이라 쓰지만 정확히는 **개별 생산 실행(run)** 단위. 도메인 아는 사람은 이 차이를 압니다.

보조 데이터 — APS (Scania 트럭 부품): $60,000 \times 171$. 공식 비용비 $10:500 = 1:50$ 이 문제 정의에 명시되어 있어, 우리가 임의로 정한 값이 아닌 유일한 검증 사례.

이 데이터의 난점 3가지 (실제 산업 데이터의 전형):

- 1. **극심한 불균형** — 93%가 정상. "전부 정상"이라 찍어도 정확도 93% → **정확도는 무의미한 지표**
- 2. **고차원** — 센서 590개인데 샘플 1,567개
- 3. **결측** — 센서마다 값이 비어 있는 곳이 산재

3. 용어·수식 사전

3-1. 분류 성능 관련

혼동행렬 (Confusion Matrix)

예측과 실제를 교차한 2×2 표. 모든 비용 계산의 기본 단위입니다.

	실제 불량	실제 정상
불량으로 예측	tp (True Positive, 제대로 잡음)	fp (False Positive, 과검)
정상으로 예측	fn (False Negative, 놓침=미검)	tn (True Negative, 제대로 통과)

- **정밀도(precision)** = $tp / (tp+fp)$ — "불량이라고 한 것 중 진짜 불량 비율"
- **재현율(recall)** = $tp / (tp+fn)$ — "실제 불량 중 잡아낸 비율"

AUC (Area Under ROC Curve)

정의: 무작위로 뽑은 불량 하나와 정상 하나를 찾을 때, **모델이 불량에 더 높은 점수를 줄 확률**

- 0.5 = 동전 던지기 (무작위)

- 1.0 = 완벽
- 우리 모델 = 0.731

0.73은 강한 모델이 아닙니다. 그런데 이게 우리 프로젝트의 논지입니다 — 모델 성능은 이 문제의 병목이 아니다.

ROC 곡선과 볼록껍질(Convex Hull)

ROC 곡선: 임계값을 0부터 1까지 움직이며 (거짓양성률, 재현율)을 찍은 곡선.

볼록껍질: 그 점들을 감싸는 가장 바깥쪽 껍질. 껍질 **안쪽에 있는 점은 "열등한 임계값"입니다 — 같은 재현율을 더 적은 과검으로 달성하는 다른 임계값이 있다는 뜻이니깐요.

핵심: 껍질 위의 정점(vertex)만이 "어떤 비용비에서든 최적일 수 있는" 임계값입니다.

SECOM에서는 300개 임계값 중 약 15개만 정점입니다. → "검사율을 12%로 미세조정하는 건 무의미하다. 효율적 정책은 이산적이다."

고전 결과: 볼록껍질의 접선 기울기 = 비용비. 우리 역산 모드가 이걸 비용 언어로 번역한 것입니다.

3-2. 검증 방법 관련

OOE (Out-Of-Fold) / 교차검증

데이터를 5조각으로 나눠 4조각으로 학습하고 1조각을 예측 → 5번 반복. 모든 샘플이 "학습에 안 쓰인 상태"로 예측됩니다.

Nested CV (중첩 교차검증) / 낙관 편향

문제: 임계값을 "평가 데이터를 보고" 고르면 성능이 부풀려집니다. 시험 문제를 미리 보고 공부하는 것과 같습니다.

해결: 바깥 fold(평가용)를 건드리지 않고, 안쪽 fold에서만 임계값을 고릅니다.

예선에서 이걸 적용해 절감률을 39.2% → 37.9%로 스스로 낮췄습니다. 손해 보는 방향의 정정이라 신뢰도 신호가 됩니다.

seed (난수 시드)

데이터를 어떻게 5조각으로 나눌지 결정하는 난수. seed를 바꾸면 결과가 달라집니다.

우리는 50개 seed로 반복해 결과의 분포를 봅니다. 왜냐하면:

양성이 104개뿐이라, fold 하나당 불량이 ~20개입니다. 이 표본으로 뽑은 숫자는 흔들립니다. 단일 숫자를 발표하면 안 되는 이유가 이것입니다.

대응 검정 (Paired test)

같은 seed에서 A와 B를 둘 다 재고, seed별 차이 $d = A - B$ 의 분포를 봅니다.

직관: 두 신발의 편안함을 비교할 때, 다른 사람 100명에게 각각 신기는 것보다 같은 사람이 양 발에 하나씩 신는 게 훨씬 정확합니다. seed 자체의 변동이 상쇄되니까요.

- Wilcoxon 부호순위 검정: 대응 차이가 0인지 검정하는 비모수 방법

- **승률:** "50 seed 중 몇 번 A가 이겼나"

Wilson CI (신뢰구간)

비율(예: 정밀도 4.9%)의 신뢰구간을 구하는 방법. **표본이 작을 때** 단순 방법보다 정확합니다.

우리는 "IForest 정밀도 4.9%"가 손익분기선 7%보다 낮다고 단정하려다, **Wilson CI가 [1.2%, 14.3%]로 7%를 감싸는 걸 확인하고 "판정 불가"로 후퇴했습니다.**

BH-FDR (다중비교 보정)

문제: 98개 센서를 각각 검정하면, 아무 신호가 없어도 평균 5개가 우연히 "유의"하게 나옵니다 (5% 유의수준 × 98회).

해결: Benjamini-Hochberg 방법으로 임계값을 조정.

결측 신호 검정에서 이걸 적용해, **64개 클러스터 중 6개가 $q < 0.10$ 통과했습니다.**

순열 검정 (Permutation test)

원리: 라벨을 무작위로 섞어서 같은 계산을 수백~수천 번 반복 → ******"우연히 이 정도 나올 확률"을 직접 셉니다.

우리는 "rec = min(가드, 교차)가 안정적"이라는 주장을 이걸로 기각했습니다. 셔플해도 비슷하게 좁게 나왔거든요(하위 20%).

부트스트랩 / 클러스터 부트스트랩

표본을 복원추출로 여러 번 다시 뽑아 통계량의 분포를 만드는 방법.

클러스터 부트스트랩: 관측이 독립이 아닐 때(예: 같은 seed에서 나온 여러 값), **seed 단위로 재추출** 합니다. 우리는 "n=66"을 독립으로 착각했던 걸 이걸로 바로잡았습니다(유효 n=10).

3-3. 비용 모델 파라미터 ★ 가장 중요

기호	이름	뜻
C_{test}	검사 비용	건당 검사비. 1로 정규화 (기준 단위)
C_{leak}	유출 손실	불량이 고객에게 갔을 때 손해
C_{scrap}	폐기 손실	양품을 잘못 버렸을 때 손해
c_l	유출:검사 비용비	$C_{\text{leak}} / C_{\text{test}}$ — "불량 1건 유출 = 검사 몇 건 값?"
c_s	폐기:검사 비용비	$C_{\text{scrap}} / C_{\text{test}}$
β (베타)	검사 검출률	검사해도 놓칠 수 있음. $\beta=0.95$ 면 5%는 못 잡음
α (알파)	양품 오페기율	검사 중 멀쩡한 걸 버릴 확률
γ (감마)	리페어 성공률	디스플레이 특화. 불량을 고칠 확률

기호	이름	뜻
V	리페어 회수가치	고쳐서 살렸을 때 회수하는 가치

★ 유효 파라미터 (프로젝트 최대 발견)

수식을 전개해보면 β 와 α 가 단독으로는 절대 나타나지 않습니다. 항상 짝을 이룹니다:

$$\begin{aligned}\lambda \text{ (람다)} &= \beta \times c1 && \leftarrow \text{유효 유출비용} \\ \mu \text{ (뮤)} &= \alpha \times cs && \leftarrow \text{유효 오펜기비용} \\ \Lambda \text{ (대문자 람다)} &= \beta \times (c1 + \gamma V) && \leftarrow \text{리페어까지 흡수}\end{aligned}$$

의미: "검출률 β 가 0.95인 걸 어떻게 압니까?"라는 질문이 **원천 차단**됩니다. β 는 $c1$ 과 **수학적으로 구분이 불가능**하므로 따로 알 필요가 없습니다.

발표 한 줄: "파라미터를 5개로 늘렸더니, 의사결정은 2개로 결정된다는 걸 발견했습니다."

R_eff (유효 비용비)

임계값을 정하는 단 하나의 숫자:

$$R_{\text{eff}} = (\Lambda + \mu - 1) / (1 + \mu) \quad \text{※ 간단한 경우 } R \approx \lambda - 1$$

임계값은 R 하나로 결정되고, 전략 선택은 (λ, μ) 2차원입니다.

3-4. 드리프트 관련

PSI (Population Stability Index)

두 시점의 분포가 얼마나 달라졌는지 재는 지표. 보통 ≥ 0.2 넘으면 "크게 변했다"로 봅니다.

domain classifier (도메인 분류기)

아이디어: "이 데이터가 전반기 것인지 후반기 것인지" 맞히는 분류기를 학습시킵니다.

- AUC 0.5 $\rightarrow$ 구분 불가 = 드리프트 없음
- AUC 0.98 $\rightarrow$ **센서값만 보고 언제 데이터인지 거의 맞힘** = 드리프트 심함

우리 결과: **0.977** (강한 입력 드리프트)

반사실(counterfactual) 통제

"Q4의 암묵 비용비가 35로 높다"는 결과가 나왔을 때, 그게 진짜 **비용구조 변화**인지 **불량률이 낮아져서 생긴 산술 효과**인지 구분하는 방법: Q4를 Q2와 같은 불량률로 리샘플링해서 다시 계산.

결과: 35 $\rightarrow$ **8.0으로 붕괴** $\rightarrow$ "대부분 유병률 효과"

3-5. XAI 관련

SHAP (SHapley Additive exPlanations)

각 센서가 예측에 얼마나 기여했는지를 게임이론(새플리 값)으로 배분하는 방법.

- 전역(global) SHAP: 평균 |SHAP| → "어느 센서가 전체적으로 중요한가"
- 국소(local) SHAP: 개별 run에 대해 → "이 run은 왜 불량으로 판정됐나"

⚠ SHAP은 인과가 아닙니다. "S59를 조정하면 불량이 준다"가 아니라 "**S59를 먼저 점검하라"입니다.

Jaccard 유사도

두 집합이 얼마나 겹치는지. $(|교집합| / |합집합|)$.

우리는 SHAP 상위 집합의 seed 간 Jaccard가 0.20(많이 흔들림)임을 확인하고, "**S59 하나만 견고, 나머지는 후보군"으로 정직하게 좁혔습니다.

4. 파이프라인 전체 흐름

```
[원본 CSV]  SECOM 1,567 run × 590 센서 (불량 104건, 6.64%)

├─ ① 입력 어댑터 ─── 라벨열·양성클래스 지정, 결측토론 흡수
├─ ② 전처리 ─── 중앙값 대체 → 상수 제거 → 표준화
│              590 → 474개 (실질 독립 290개)
├─ ③ 예측 모델 ─── LightGBM, nested 5-fold OOF, 50 seed
│              AUC 0.731 ± 0.014
├─ ④ Cost Layer ───  $\lambda = \beta \cdot cl$ ,  $\mu = \alpha \cdot cs$ ,  $\Lambda = \beta (cl + \gamma V)$ 
│   ★ 커널      3전략 비용 / 임계값 / 닫힌해 / 경계분포
│              4중 검증 통과
├─ ⑤ 응용층 ──┬─ 역산 ──── 검사율 → 함의 비용비 R
│              └─ 공정최적화 ── 관리한계선, "모델이 필요한가"
│              └─ 드리프트 ──── 입력/유병률/관계 3성분 분해
│              └─ 이상탐지 ──── 2차 필터 손익분기 = 한계정밀도
│              └─ XAI ──── SHAP 전역·국소 + 3중 검증
│              └─ 디스플레이 ── 리페어  $\gamma V$ , 검출률  $\beta$ 
└─ ⑥ 산출물 ─── 웹 시뮬레이터 (단일 HTML, 4탭)
```

핵심 구조: 응용층 6개가 전부 같은 커널(④) 위에 얹혀 있습니다. 새 프레임워크를 만든 게 아니라 하나의 축이 여러 방향으로 뻗은 것입니다.

5. 단계별 상세 (1) — 전처리와 모델

5-1. 전처리

결측을 어떻게 할까

결측 있는 행을 지우면 1,567개가 0개가 됩니다. 열을 지우면 590개가 52개만 남습니다. → 삭제가 불가능하므로 채워야(대치) 합니다.

8가지를 비교했습니다: 중앙값 / 평균 / 0채움 / 최빈값 / KNN / 중앙값+결측여부 / 고결측제거+중앙값 / 대치안함

0채움이 AUC 0.762로 1위였지만 중앙값(0.750)을 선택했습니다.

왜? 난수만 15번 바뀌 짝지은 재검정을 했더니:

- 0채움 승률 8/15 (53%) — 거의 동전 던지기
- $t = 1.14$ (유의하려면 2.0 필요)

직관: 시험을 한 번 봐서 A가 92점, B가 90점이라고 A가 더 똑똑한 게 아닙니다. 15번 봤더니 8번만 A가 이겼다면, 그 2점은 실력이 아니라 그날의 운입니다.

→ 가장 단순하고 안정적인 중앙값 채택.

본선 추가 (오늘): 이 8종을 비용 기준으로도 재비교했습니다. 대응검정 결과 AUC도 비용도 둘 다 유의차 없음 → "AUC≠비용의 두 번째 증거"라는 주장은 철회. 정직한 결론은 "결측 전략은 어느 잣대대로도 구분되지 않는다."

★ 순서 민감성 — 그리고 그것이 사실은 순서 문제가 아니었다는 것

처음 관찰: 같은 두 연산인데 순서만 바꿨더니 —

순서	살아남은 센서
중앙값 대치 → 상수 제거	474개
상수 제거 → 중앙값 대치	53개

9배 차이. 첫날 지적받고 21라운드 동안 미해결로 남았던 항목입니다.

오늘 규명한 진짜 원인:

진단	값
전체 센서	590
결측이 있는 열	538
완전한 열 (결측 0)	52 ← "53"의 정체
관측값 기준 상수 열	116

메커니즘: `np.var` (numpy 기본 분산)는 NaN을 전파합니다. 결측이 하나라도 있으면 분산 = NaN 이 되고, `NaN > 0`은 False → 제거됩니다. → 결측 있는 538열이 전부 죽고 완전한 52열만 생존.

검증표:

분산 계산 방법	생존 센서	AUC
<code>np.var</code> (NaN 전파)	52	0.610
<code>np.nanvar</code> (NaN 무시)	474	0.751
sklearn 1.9 <code>VarianceThreshold</code>	474	0.751

⚠ "sklearn 탓"이 아닙니다. sklearn 1.9는 내부적으로 `nanvar`를 써서 474를 유지합니다. 우리 코드의 분산 계산이 원인이었습니다.

★ ★ 그리고 순서는 사실 무관합니다 (증명됨)

NaN을 제대로 다루면 어떤 순서로도 474가 나옵니다. 대수적으로 증명됩니다:

중앙값 대치는 관측 분산이 0인 열만 상수로 만듭니다.

- 관측값이 전부 v면 → 중앙값도 v → 채워도 전부 v → 상수
- 관측 분산 > 0이면 → 채워도 > 0 → 비상수

∴ "대치 후 상수" 집합 = "관측값 기준 상수" 집합 → 두 연산은 교환 가능(commute)

실측 확인: 두 집합이 완전히 동일(474개, True).

최종 메시지:

"순서 문제로 보였던 것은 순서 문제가 아니었다. 진짜 원인은 분산 계산의 NaN 처리다. `np.var`는 결측 있는 신호센서 421개를 조용히 버려 AUC가 0.751 → 0.610으로 무너진다. 라 이브러리 함수의 NaN 동작을 확인 없이 쓰면 안 된다."

★ 결측 신호와의 연결

버려진 421개가 정확히 ***결측이 있는 센서***들입니다. 그리고 별개 실험에서 결측 자체가 신호 임을 확인했습니다:

센서 값	불량률
있는 run	8.3%
없는 run	4.6%

Fisher 검정 p=0.003, 클러스터+BH-FDR 보정 후 6개 클러스터 생존.

왜? 센서 값이 비는 데는 이유가 있습니다. 그 공정을 건너뛰었거나, 특정 레시피에서 계측을 안 하거나. → "결측 패턴"이 공정 조건을 간접적으로 알려줍니다.

두 독립 실험이 같은 곳을 가리킵니다: SECOM에서 결측은 잡음이 아니라 신호가 실린 곳입니다.

추가 발견 — 중복 센서

|상관계수| > 0.95로 묶으면 474개 → 290개가 실질 독립. 나머지는 사실상 같은 센서의 복사본입니다.

클러스터링 방법 주의: 연결요소(union-find) 방식은 A~B(0.96), B~C(0.96)이면 A,C를 묶는데 A~C는 0.85일 수 있습니다(연쇄 문제). 우리는 greedy(모든 구성원이 시드와 직접 0.95 이상) 방식을 채택해 과병합을 피했습니다. → 290이 정본.

5-2. 예측 모델

모델 선정

RandomForest / LightGBM / XGBoost / Soft Voting 4종 비교 → AUC 0.72~0.75에 수렴.

RandomForest가 근소하게 1위(0.752 vs 0.727)였지만:

- 난수 20회 재실험에서 RF가 19/20 승 (통계적 우위는 맞음)
- 그런데 그 격차가 잡음의 1.38배 (Dummy 모델과의 격차는 잡음의 19.4배)

직관: "이길 확률은 높지만, 이겨봐야 별 차이 없다."

결정적 근거: 비용비 구간 59개에서 두 모델의 최종 의사결정이 88% 일치했습니다(52/59). 갈린 7개도 44~50:1이라는 좁은 구간뿐.

즉 성능 차이가 결정을 바꾸지 못합니다. → 배포·운용이 편한 LightGBM 채택.

확정 성능

항목	값	프로토콜
모델 AUC	0.731 ± 0.014	nested 5-fold OOF, 50 seed
단일 센서 S59	0.679 ± 0.061	inner선택/outer평가, 50 seed
AUC 격차	0.052	대응 0.051, CI [0.046, 0.058], 역전 1/50

"단일 센서만 사용"이 무슨 뜻? 모델을 안 쓰고 센서 값 자체를 점수로 쓰는 것입니다.

- 모델: 474개 센서 → LightGBM → 확률 0.73
- 단일 센서: S59 값이 어떤 값 이상이면 재검사

건강검진 비유: 혈액 474항목을 AI에 넣는 것 vs 공복혈당 하나만 보고 "126 넘으면 정밀검사". 후자는 AI도 계산도 필요 없습니다. 숫자 하나와 기준선 하나뿐.

★ K-곡선 — 센서 몇 개면 충분한가

센서를 기여도 순으로 줄 세우고, 상위 K개만 남겨 다시 학습했습니다.

K	AUC	해석
1	0.634	센서 1개
10	0.687	10개로 이득의 51% 회수
50	0.711	
100	0.738	정점
474	0.729	더 넣었는데 내려감

두 가지 발견:

1. 상위 10개가 이득의 절반을 가져옵니다
2. 100개 넘으면 오히려 나빠집니다 (대응검정 10/10, $p=0.002$, 다만 격차 -0.009 로 근소)

왜 센서를 더 주는데 성능이 떨어지죠? 하위 374개는 정보 없는 잡음입니다. 모델이 잡음 속 우연한 패턴을 학습하는 걸 **과적합**이라 합니다. 비유: 시험공부를 핵심 교재 3권으로 하는 게, 관련 없는 책 100권을 섞어 보는 것보다 낫습니다.

실무 함의: 센서를 늘리는 건 공짜가 아닙니다 — 계측 장비·시간, 저장 인프라, 엔지니어가 감시할 대상 수. → "590개를 다 모으고 관리할 이유가 없다. 상위 100개면 충분하고, 10개로도 절반은 회수된다."

6. 단계별 상세 (2) — Cost Layer (프로젝트의 심장)

6-1. 예선 모델의 구멍

예선에서는 이렇게 계산했습니다:

$$\text{비용} = fp \times C_{FP} + fn \times C_{FN}$$

문제 1: tp(제대로 잡아서 검사 보낸 것)의 비용이 0입니다. 불량을 정확히 골라 재검사로 보냈으면 검사비가 드는데 수식에 없습니다.

비유: 식당에서 "주문 실수한 것"만 비용에 넣고, 제대로 만든 요리의 재료를 안 세는 격입니다.

문제 2: C_{FP} 가 불필요한 검사비와 양품 폐기 손실을 하나로 뭉쳤습니다. 완전히 다른 것인데요.

6-2. 재설계 — 3파라미터 모델

세 가지 전략의 총비용:

```
전수 통과 =  $n_{pos} \times c_l$ 
              (아무것도 검사 안 함 → 불량 전부 유출)

전수 검사 =  $N$ 
              +  $n_{pos} \times (1-\beta) \times c_l$ 
              +  $n_{neg} \times \alpha \times c_s$ 
              ← 전부 검사비
              ← 검사했는데 놓친 불량
              ← 양품 오페기

선별 검사 =  $(tp+fp)$ 
              +  $fn \times c_l$ 
              +  $tp \times (1-\beta) \times c_l$ 
              +  $fp \times \alpha \times c_s$ 
              ← 지목한 것만 검사비
              ← ★ 애초에 검사 안 해서 놓침
              ← 검사했는데 놓침
              ← 양품 오페기
```

"전수검사도 완벽하지 않다"가 왜 중요한가

검사도 사람·장비가 하는 거라 100%가 아닙니다.

- β (검출률): 디스플레이의 Mura(얼룩)나 점결함은 전기 검사로 안 잡히고 광학·관능 검사가 필요합니다
- α (오페기율): 측정 오차, 가드밴드 때문에 멀쩡한 걸 버립니다

선별검사와 전수검사의 차이는 항 하나뿐입니다:

	전수검사	선별검사
검사비	전부	일부만  절감
검사했는데 놓침	있음	있음 (동일)
양품 오페기	전부에 대해	검사한 것에만  절감
안 검사해서 놓침	없음	있음  리스크

선별검사 = "검사비와 오페기를 아끼는 대신, 안 본 것 중 불량이 있을 위험을 사는 것" 그 교환이 이득인지 판정하는 게 우리 도구입니다.

예선 모델은 $\beta=1, \alpha=0$ 을 암묵 가정했습니다. 즉 "전수검사는 완벽하다"고 봤죠. 그러면 전수검사를 실제보다 좋게 평가하게 되어, 스스로 손해를 보고 있었습니다.

6-3. ★ 최대 발견 — 파라미터를 늘렸더니 차원이 줄었다

앞서 3-3에서 설명한 λ, μ, Λ 붕괴입니다. 세 전략을 전개하면 β 와 α 가 단독으로 나오지 않습니다.

$$\lambda = \beta \cdot c1, \quad \mu = \alpha \cdot cs, \quad \Lambda = \beta (c1 + \gamma V)$$

→ 의사결정은 (λ, μ) 2차원으로 완전 결정

부수 효과: 예선의 2-파라미터 모델과의 관계도 수식으로 드러냅니다.

$$\begin{aligned} C_{FP} &= 1 + \mu && \leftarrow \text{검사비}(1) + \text{오페기 리스크}(\mu) && \leftarrow \text{"뭉갸다"} \text{의 증명} \\ C_{FN} &= \lambda - 1 && \leftarrow \text{유출손실} - \text{절약한 검사비} \\ R_{eff} &= (\lambda + \rho - 1) / (1 + \mu) \end{aligned}$$

→ 예선 결과가 폐기되지 않습니다. 파라미터만 재해석하면 됩니다.

6-4. ★ 경계의 항등식

"선별 검사가 유리한 비용비의 상한"을 수식으로 풀면:

$$\begin{aligned} \lambda_{max} &= (tn + fn) / fn \\ &= (\text{검사 안 한 건수}) / (\text{놓친 불량 수}) \end{aligned}$$

직관적 의미: "불량 1건을 흘리는 대가로 검사 몇 건을 아꼈는가." 유출 비용이 이 비율보다 크면 선별 검사가 손해입니다.

이건 대수적으로 증명된 항등식이라 데이터와 무관하게 참입니다. 그리고 여기서 중요한 귀결이 나옵니다:

이 값은 비용최적 임계값(재현율 중앙 0.96)에서 평가됩니다. → 경계를 결정하는 건 ROC 곡선 전체의 면적(AUC)이 아니라 고재현율 꼬리의 국소적 모양입니다. → 예선 명제 "AUC 1등 ≠ 비용 1등"의 정밀한 확장.

6-5. ★ 경계는 단일 숫자로 말할 수 없다 (헤드라인)

경계를 구했더니 하나가 아니었습니다.

경계	정의	중앙값	IQR
경제 교차	실제로 비용이 역전되는 점	54	[46.2, 77.8]
운영 가드	검사율 90% 도달점	56	[49.5, 68.5]

두 경계는 평균적으로 거의 같은 위치에 있지만:

- 상관계수 $r = 0.12$ (무상관)
- 50 seed 중 26번 순서가 뒤바뀜

직관: 두 온도계가 평균은 같은 값을 가리키는데, 순간순간 서로 상관없이 흔들려서 어느 쪽이 높은지가 계속 바뀌는 상황. 어느 하나를 "정답"이라 하면 **절반의 확률로 틀립니다.**

→ "실익 상한은 단일 숫자로 확정할 수 없다. 분포로만 말할 수 있다."

이게 프로젝트에서 가장 정직하고 강한 발견입니다.

6-6. 4중 검증 + 발견된 버그 2건

검증	방법	결과
대수 정합	단히해 vs 직접 비교, 14,980점	불일치 0
회계 정합	샘플 하나씩 for문으로 비용 누적 (brute-force)	오차 2e-11
캐시 생성	원점수에서 직접 센 혼동행렬 vs 저장값	0/1500 불일치
역방향	R → 검사율 → 역산 → R 복귀, 250회	이탈 0

왜 **brute-force**가 필요한가? 집계 공식끼리 비교하면 **둘 다 똑같이 틀렸을 때** 못 잡습니다. 그래서 완전히 다른 경로(샘플 하나씩 세기)로 같은 답이 나오는지 확인했습니다. **장부끼리 맞춰본 게 아니라, 실제로 돈을 하나씩 세본 것.**

★ 실제로 발견된 버그 2건 (둘 다 "조용히 틀리는" 유형)

#	버그	단서	영향
①	라벨 오정합 — 시간정렬된 예측점수를 원본순서 라벨과 짝지음	AUC 0.486 (자기 모델이 무작위 이하 = 구조적 불가)	ROC 정점 수가 15 → 7로 잘못 나옴
②	NaN 분산 전파 — <code>np.var</code> 가 결측 있는 열을 전부 제거	생존 센서 53 ≈ 완전한 열 52개	AUC 0.751 → 0.610

둘 다 에러를 내지 않고 조용히 틀린 결과를 냈습니다. 검증 체계가 없었으면 발표까지 갔을 겁니다.

→ 이후 파이프라인에 `assert auc > 0.55`, `assert N > 1000` sanity check 추가.

6-7. 파이프라인 레지스트리 (숫자 불일치 근절)

22라운드 동안 AUC가 0.718~0.751로 떠다녔습니다. 원인을 규명해 표로 달았습니다:

결론: 전처리·하이퍼파라미터는 전부 동일. 산포 원인 3가지:

1. **seed 변동** — 50 seed 범위 [0.689, 0.760]. 떠다닌 값 전부 이 안
2. **데이터 행 순서** — anomaly 계열은 시간순 정렬(leave-mode-out용) → fold 분할이 달라짐 (0.7325 vs 0.7183)
3. **라벨 오정합 버그** (위 ①) — 수정 완료

7. 단계별 상세 (3) — 응용층

7-1. ★ 역산 모드 — 최대 차별화

문제

우리가 발견한 사실: "비용 구조를 정확히 아는 것이 모델을 교체하는 것보다 5배 중요하다" (비용 비 오판 시 최대 41.3% 손실 vs 모델 교체 이득 8.4%).

그런데 해법이 *****"사용자가 비용비를 입력하세요"*****였습니다. 이걸 문제를 떠넘기는 겁니다.

현장 엔지니어는 자기 회사의 미검 비용을 모릅니다.

해법 — 되묻지 말고 역산한다

현업은 비용비는 몰라도 **현재 정책은 압니다.** ("우리는 상위 12%를 재검사한다")

검사율	함의 비용비 R
12%	[6.4, 7.1]
30%	[10.3, 13.6]
50%	[19.2, 24.7]

"귀사가 상위 12%를 재검사하고 있다면, 그 정책이 최적이라면 유출 손실을 검사비의 6~7배로 평가하고 있다는 뜻입니다. 이 값이 타당합니까?"

이건 경제학의 **현시선호(revealed preference)** 논리이고, ROC 이론의 표준 결과(**블록깍질 접선 기울기 = 비용비**)를 비용 언어로 번역한 것입니다.

3단 환산 사다리

R (암묵 비용비)	← 입력 불필요, ROC만으로 나옴
Λ (유효 유출비용)	← μ를 알면
c1 (원 비용비)	← β 까지 알면

위로 갈수록 가정이 적습니다. λμ 붕괴 발견의 실용적 결실입니다.

부수 발견 — 효율적 정책은 소수다

300개 임계값 중 블록깍질 정점은 **약 15개**(해상도·허용오차에 따라 14~17). APS는 29개.

"검사율을 12%로 미세조정하는 건 무의미합니다. 효율적 정책은 이산적이며, 가장 가까운 정점은 11.4%입니다."

7-2. ★ 공정 최적화 — "모델이 필요한가?"

핵심 통찰

- 지금까지: 모델 점수 공간에서 임계값을 정함
- 공정 최적화: 센서 값 공간에서 관리 한계선을 정함

수학적으로 같은 문제입니다. Cost Layer를 한 줄도 안 바꾸고 재사용합니다.

S59 비용 최적 관리한계선

cl	최적 관리상한	불량 커버리지	정밀도
10	19.3%	46.9%	16.1%
15	21.8%	52.9%	16.1%
20	37.7%	61.7%	10.9%
30	54.5%	77.5%	9.4%

- cl=15에서 21.8% — 눈으로 고른 "십분위 8~9(상위 20%)"와 일치 → 커널이 확인
- ⚠ cl 의존성이 큼 → 발표에 "cl=15에서"를 반드시 명시

결과 — AI가 "AI 불필요"를 판정하다

센서 1개(S59) 관리한계선 vs 474센서 LightGBM을 같은 잣대로 비교:

cl (유출:검사)	결과
cl ≤ 15	대등 (95% CI가 0 포함)
cl ≥ 16	모델 유의 우위 (손익분기)
cl ≥ 35	둘 다 전수검사로 수렴

AUC 격차는 0.052로 존재합니다. 그런데 저비용 구간에서 비용 차이가 없습니다.

- "474센서 모델이 단일 센서 관리한계선 대비 유의한 이득을 내는 구간은 $cl \in [16, \sim 35]$ 에 한정된다. 그 밖이라면 모델 구축·운영 비용을 지출할 이유가 없다."
- ⚠ 단, "모델 없음"의 비용이 0은 아닙니다. 단일 센서 정책도 라벨 데이터와 임계값 최적화가 필요합니다. 차이는 474센서 수집·파이프라인·재학습·모니터링 인프라의 유무입니다.

7-3. 드리프트 — 시간이 지나면?

11개월을 시간 4등분(quantile, 라벨 안 보고 자름)해서 분석했습니다.

성분	결과
입력 드리프트	강함 — domain AUC 0.977 , PSI>0.2가 82/474 센서
유병률	유의하나 비단조 (6.6% → 11.2% → 5.1% → 3.6%)
관계/성능	대체로 유지

quartile로 자른 이유: 유병률을 본 뒤에 가장 차이 큰 지점에서 자르면 결과에 조건을 건 분할이 되어 p값이 무의미해집니다. 라벨을 안 보고 자른 덕에 **Q2 정점(11.2%)**이라는 비단조성을 발견할 수 있었습니다.

★ 상식을 뒤집는 실무 권고

상식: "센서 분포가 변했으니 재학습해야 한다" 데이터: 입력은 크게 변했는데 성능은 유지됐다.

"입력 드리프트 감시(PSI 등)만으로 재학습을 판단하면 잦은 오경보가 발생합니다. 82개 센서가 기준을 넘었는데 성능은 유지됐습니다. 입력 감시는 값싸지만 재학습 트리거로는 부적합하며, 성능·비용 지표를 함께 봐야 합니다."

유병률 통제 반사실

시간에 따라 암묵 비용비 R이 변했습니다(Q2 4.6 → Q4 35). 드리프트일까요?

Q4를 Q2와 같은 불량률로 리샘플링했더니 R이 35 → 8.0으로 붕괴했습니다.

"암묵 비용비의 시간 변화는 비용구조 드리프트가 아니라 불량률 변화의 산술적 재서술이다."

경계 항등식 $\frac{(tn+fn)}{fn}$ 을 이해하고 있었기에 가능한 분해입니다 — 불량률이 절반이 되면 fn이 줄고 tn이 늘어 **경계가 기계적으로 올라가기** 때문입니다.

부산물 — S59는 시간 대리변수가 아니다

검증	결과
domain classifier 중요도	25/474위 (상위 아님)
시간과 Spearman 상관	-0.16 (약함)
구간 내 AUC	0.54 / 0.70 / 0.73 / 0.71

왜 중요한가? S59가 "시간을 알려주는 센서"였다면, ***"센서 1개로 474모델과 대등"이 "시간 정보 하나로 대등"***이라는 전혀 다른 얘기가 됩니다. 실무에서 흔한 함정입니다.

7-4. 이상 탐지 — "모르는 불량"은 잡을 수 있나

지도학습은 과거에 본 불량 모드만 배웁니다. 그래서 "정상이 아닌 것"을 탐지하는 IsolationForest를 2차 필터로 얹어봤습니다.

★ 발견 — 손익분기 = 1차 모델의 한계 정밀도

2차 필터가 비용을 줄으려면 넘어야 할 정밀도:

$$\text{필요 정밀도} = (1 + \mu) / (\wedge + \mu)$$

그런데 이 값이 1차 모델의 임계값을 한 칸 내릴 때의 한계 정밀도와 정확히 같습니다.

의미: 2차 필터의 경쟁 상대는 "아무것도 안 하기"가 아니라 *******"그냥 임계값을 조금 더 내리기"***입니다. 손익분기를 넘으려면 1차 모델과 **직교하는 정보**를 가져야 합니다.

예시값: cl=15 → 7.0%, cl=30 → 3.5%, cl=50 → 2.1%

항등식의 데이터 확증: 임계값 내리기(B)의 실측 정밀도가 손익분기선을 따라갑니다.

- cl=15: 실측 **6.4%** vs 이론 **7.02%**
- cl=30: 실측 **4.3%** vs 이론 **3.51%**

실측 결과: IsolationForest는 임계값 내리기를 이기지 못했습니다(표본 있는 유일점 cl=15에서 B가 6:2 우세). → **"IForest 실패"가 아니라 "IForest는 임계값 내리기보다 낫지 않다"**

라벨의 가치 정량화

점수	AUC	cl=15 순정보*
지도학습 (라벨 있음)	0.725	+23.5%p
이상탐지 (라벨 없음)	0.547	+5.4%p
무작위	0.500	전수통과보다도 낮음

*순정보 = 절감률 - 무료 기준선(모델 없이 전수통과/전수검사 중 싹 쪽)

무료 기준선이 왜 필요한가? cl이 작으면 "일부만 검사한다"는 구조만으로 절감이 나옵니다. 무작위 점수로도요. 기준선을 안 그으면 **정보가 없는 점수의 절감을 성과로 착각**합니다.

정직한 한계

SECOM의 모든 불량은 라벨에 있습니다 → 지도학습이 이미 다 봤습니다. **"모르는 불량을 잡는 다"**는 이 데이터로 실증 불가입니다. 주장은 "기준 유도 + 메커니즘"까지만.

7-5. XAI — 무엇을 점검할까

SHAP + 3중 검증

590개 중 **S59**가 최상위. 화면에 올리기 전에 먼저 검증했습니다:

검증	결과
① 시간 대리변수 아님	domain 25/474위, 구간 내 AUC 0.70~0.73
② seed 안정	20 seed에서 중앙 1위, top-3 85%, top-10 95%
③ 독립 신호	중복 클러스터 크기 1 (다른 센서와 안 겹침)

정직하게 줬힌 것: 상위 집합은 흔들립니다(Jaccard 0.20). → "S59 하나만 견고, 2~12위는 후보군"

국소 설명 (SHAP 워터폴)

"이 run은 왜 재검사 대상인가?"에 답합니다.

- 고위험 run(점수 0.945): S59가 불량 쪽으로 +0.6 밀고 있음
- 저위험 run(점수 0.004): 모든 센서가 정상 쪽

사슬 완성

SHAP이 S59 지목 → 3중 검증 통과 → 조건부 불량률(십분위 8~9에서 17%, 전체 6.6%의 2.5배) → 비용 최적 관리한계선 21.8% → 그 센서 하나로 474모델과 대등

"XAI가 알려준 것이 곧 의사결정이 된다."

⚠ SHAP은 인과가 아닙니다. 우리 도구의 출력은 실행 지시가 아니라 DOE(실험 계획) 우선 순위입니다. 590개 중 무엇을 먼저 실험할지 순서를 정해주고, 인과 검증은 실제 DOE의 몫입니다.

7-6. ★ 디스플레이 특화 (오늘 완성)

리페어의 역설

디스플레이는 반도체와 달리 레이저 리페어가 가능합니다. 불량을 찾으면 고칠 수 있죠.

직관적으로는 "리페어가 되면 선별검사 여유가 늘어날 것 같습니다." 그런데 계산해보니 반대였습니다.

$\Lambda = \beta (c_1 + \gamma V)$ ← 리페어는 유출비용을 γV 만큼 "올리는" 것과 수학적으로 동일

왜? 불량을 놓치면 유출 손실만 잃는 게 아니라 리페어로 회수할 수 있었던 가치까지 잃습니다 (기회비용).

격자 실험 결과 (기준선 = 경제교차 달한해 52):

γ (성공률)	V=0	V=5	V=10	V=20
0.0	52	52	52	52
0.3	52	50	49	46
0.5	52	50	47	42
0.7	52	48	45	38
0.9	52	48	43	34

★ 불변량 검증: $(c1_{max} + \gamma V = 52.0)$ (격자 12점 전부, 정수 γV 8점은 정확히 52.0, 비정수 4점은 51.5~52.5 = 정수 c1 격자 ± 1 칸)

이게 왜 중요한가: 대수 유도 $(\Lambda = \beta(c1+\gamma V))$ 와 수치 결과가 소수점까지 일치합니다. 리페어 항이 커널에 올바르게 들어갔다는 자기검증입니다.

디스플레이 현실 한 점: $\gamma \approx 0.7, V \approx 20$ (가정) $\rightarrow$ 상한 52 $\rightarrow$ 38 (-27%)

"디스플레이 펌은 반도체보다 더 좁은 비용비 구간에서만 선별검사가 유효하며, 그 밖에서는 전수검사가 최적이다. 이는 실제 디스플레이 업계가 검사에 집중 투자하는 현실과 부합한다."

$\beta < 1$ — Mura·점결함

전기 검사로 안 잡히는 결함을 $\beta < 1$ 로 표현합니다.

β	실익 상한 (관측)	예측 (Λ_{max}/β) ($\Lambda_{max}=49.4$)	절대 절감차
1.00	48	49.4	479
0.95	52	52.0	509
0.85	58	58.1	572
0.70	70	70.6	673

두 가지를 동시에 보여줍니다:

- $\lambda = \beta \cdot c1$ 붕괴 구조의 수치 검증 (예측과 관측이 격자 1칸 내 일치)
- 전수검사가 불완전할수록 선별검사가 상대적으로 유리해진다 — 절대 절감차도 479 $\rightarrow$ 673으로 증가(분모 팽창만이 아님)

선별이 β 열화에 덜 민감한 이유: 검사하는 건수 자체가 적기 때문입니다($tp < npos$).

8. 그림 읽는 법

8-1. `fig_repair.png` — 디스플레이 특화 (2패널)

좌: 히트맵

- **x축** = 리페어 회수가치 V (0, 5, 10, 20)
- **y축** = 리페어 성공률 γ (0, 0.3, 0.5, 0.7, 0.9)
- **셀 값** = 선별 실익 상한 cl (파랑=높음/선별 여유 많음, 빨강=낮음/더 검사해야 함)
- **각 셀 아래** = $cl_{max} + \gamma V = 52$ 불변량 확인
- **읽을 포인트**: ① $\gamma=0$ 행과 $V=0$ 열이 전부 52 → 하위호환. ② 오른쪽 위로 갈수록 빨개짐 → 리페어가 클수록 선별 여유가 줄어듦. ③ 검은 박스 = 디스플레이 가정점 ($\gamma 0.7 \cdot V 20 \rightarrow 38$)

우: β 곡선

- **x축** = 검출률 β (1.0 → 0.7, 오른쪽으로 갈수록 검사가 부정확)
- **y축** = 실익 상한 cl
- **파란 선** = 관측, **빨간 X** = 이론 예측 (Λ_{max}/β)
- **읽을 포인트**: 둘이 겹침 → 붕괴 구조 $\lambda = \beta \cdot cl$ 의 수치 검증. 그리고 β 가 낮아질수록 상한이 올라감 → 전수검사가 불완전할수록 선별이 유리

8-2. `fig_costmap_lm_secom.png` — (λ, μ) 실익맵

- **x축** = $\lambda = \beta \cdot cl$ (유효 유출:검사), **로그 스케일**
- **y축** = $\mu = \alpha \cdot cs$ (유효 오펜기:검사), **로그 스케일**
- **색**: 회색 = 전수통과 최적 / 초록 = 선별검사 최적 / 빨강 = 전수검사 최적
- **점선** = R_{eff} 등고선 (같은 임계값이 나오는 선)
- **읽을 포인트**: 초록 영역이 선별검사가 이득인 구간. λ 가 커지면(오른쪽) 빨강으로 넘어감 = 유출이 비싸면 전수검사. μ 가 커지면(위) 초록 영역이 넓어짐 = 폐기 비용이 크면 선별이 유리

8-3. `fig_seed_boundaries.png` — 경계의 seed 분산 ★ 헤드라인 그림

- **y축** = 50개 seed (각 줄이 하나의 seed)
- **x축** = cl (로그)
- ● 파랑 = 운영 가드 경계 / ■ 빨강 = 경제 교차 / ▲ 노랑 = $fn=0$ 꼬리
- **읽을 포인트**: 같은 줄에서 ●와 ■의 좌우 순서가 seed마다 뒤바뀝니다(26/50). 두 경계가 무상관($r=0.12$)이라는 시각적 증거
- **결론**: "실익 상한은 단일 숫자로 말할 수 없다"

8-4. `fig_inverse_R.png` — 역산 지지비율 곡선

- **x축** = R (유효 유출:검사 비용비), **로그**

- **y축** = "이 R에서 관측 정책이 최적이 되는 seed 비율" (0~1)
- **색깔별 곡선** = 검사율 2% / 12% / 30% / 50% / 99%
- **읽을 포인트: 봉우리** = 역산값, **폭** = 불확실성. 검사율이 커질수록 봉우리가 오른쪽으로 이동 (더 큰 비용비를 함의)
- 봉우리가 50% 미만이면 → "이 검사율은 어떤 비용비에서도 다수 지지를 못 받음 = 효율적이지 않음"

8-5. **fig_sensor_vs_model_v2.png** — 모델이 필요한가

- **x축** = c1, **y축** = 절감률 (전수검사 대비)
- **빨강** = 단일 센서 S59 관리한계선 / **파랑** = 474센서 LightGBM
- **초록 영역** = $c1 \leq 15$ (대등 구간) / **파랑 영역** = $c1 \geq 16$ (모델 필요)
- **점선** = 손익분기 $c1=16$
- **읽을 포인트:** 초록 구간에서 두 선이 겹칩니다 → 센서 1개로 충분. 그리고 c1이 커지면 둘 다 0으로 수렴 → 전수검사가 최적

8-6. **fig_K_curve.png** — 센서 몇 개면 충분한가

- **좌: x축** = 센서 수 K(로그), **y축** = AUC → $K \approx 100$ 에서 정점 후 하락
- **우: x축** = K, **y축** = 절감률, 3개 곡선 ($c1=15/20/30$)
- **읽을 포인트:** 좌측이 **K=100** 이후 평평해지거나 내려감 → 나머지 374개는 무의미

8-7. **fig_xai_stability.png** — SHAP + 안정성

- **좌: y축** = 센서명(위가 중요), **x축** = 평균 |SHAP| → S59만 빨강(검증됨), 2~12위는 회색(후보군)
- **우: x축** = S59의 SHAP 순위, **y축** = 그 순위가 나온 seed 수 → 1위에 14/20 몰림
- **읽을 포인트:** 좌측에서 S59가 압도적으로 길다는 것, 우측에서 그게 seed에 안정적이라는 것

8-8. **fig_shap_local.png** — 국소 설명 (위터폴)

- **좌:** 고위험 run (점수 0.945, 실제 불량) — 빨간 막대 = 불량 쪽으로 밀어낸 센서
- **우:** 저위험 run (점수 0.004, 실제 정상) — 파란 막대 = 정상 쪽으로 밀어낸 센서
- **읽을 포인트:** 좌측은 S59가 +0.6으로 압도적. 우측은 거의 모든 센서가 정상 쪽으로 일관되게 밀고 있음

8-9. **fig_process_cond_defect_v2.png** — 조건부 불량률

- **x축** = S59 값을 10등분한 십분위(0=낮음 → 9=높음) + 마지막에 "결측" 막대
- **y축** = 그 구간의 실제 불량률 (%), 점선 = 전체 평균 6.6%
- **오차막대** = 95% 신뢰구간
- **읽을 포인트:** 십분위 8~9에서 17%로 급등(전체의 2.5배) → 관리 상한 후보

- ⚠️ 그림 제목의 "결측은 신호 아님"은 전역 집계 기준(철회). 센서별 지시자로 재검정 시 6개 클러스터가 유의 → 결측은 신호임

8-10. — 이상탐지 (2패널)

좌: 손익분기 곡선

- x축 = cl, y축 = 정밀도(%)
- 빨간 곡선 = 손익분기 $\frac{(1+\mu)}{(\Lambda+\mu)}$ = 1차 모델의 한계 정밀도
- 보라 ♦ = 임계값 내리기(B)의 실측 → 빨간 곡선 위에 앓음 = 항등식의 데이터 확증
- 파란 ■ + 긴 오차막대 = IForest 실측 (Wilson CI) → CI가 손익분기선을 감쌌 = 판정 불가

우: 라벨의 가치

- x축 = cl, y축 = 절감률
- 회색 음영 = 무료 기준선 max(전수통과, 전수검사)
- 파랑 = 지도학습 / 주황 = IForest / 회색 점선 = 무작위
- 읽을 포인트: 무작위가 회색(기준선)보다도 낮습니다. 곡선 - 기준선 = 순정보. 지도만 큰 폭 우위 = 라벨의 가치

8-11. — 경계는 ROC 꼬리

- 좌: x축 = AUC 전체, y축 = 경계 → $r=0.28$, 산포가 큼(무의)
- 우: x축 = pAUC[재현율 0.9~1] (꼬리 지표), y축 = 경계 → $r=0.50$ (유의)
- 읽을 포인트: 우측이 더 뚜렷한 상관. 다만 seed 클러스터 부트스트랩으로는 "꼬리 > AUC" 우위가 유의하지 않음 → 층①(항등식)이 본체이고 이건 정합성 확인

8-12. 시뮬레이터 4탭

탭	입력	출력	시연 포인트
① 무엇을 점검할까 (XAI)	—	SHAP + 3중 검증 + 조건부 불량률 + 국소 워터폴	"검증된 센서 하나"
② 검사정책 판단	cl, β , μ	3전략 비용 비교 + 두 경계 병기	"단일 숫자로 말할 수 없다"가 화면에
③ 역산	검사를 슬라 이더만	함의 R 구간 + 3단 환산 + 지지곡선	가장 강한 인터랙션
④ 모델이 필요한가	—	단일센서 vs 모델 + 손익분기 cl=16	서사의 결론

⚠️ 모든 인용은 이 표에서만. 프로토콜이 다르면 값이 다릅니다.

성능

항목	값	프로토콜
모델 AUC	0.731 ± 0.014	nested 5-fold OOF, 50 seed
단일 센서 S59	0.679 ± 0.061	inner선택/outer평가, 50 seed
AUC 대응 격차	0.052	CI [0.046, 0.058], 역전 1/50
최적 센서 수 K	≈100 (이후 고원)	K=474 대응 -0.009
실질 독립 센서	474 → 290	greedy 클러스터, r >0.95

비용 (지표별 — 분모가 다르므로 혼용 금지)

값	지표	조건
31.0%	sel_vs_inspect ← 표준	SECOM cl=15, 50 seed nested
27.2%	sel_vs_floor	무료 기준선 대비
30.9%	best_vs_inspect	③그림 축 (다른 지표, 직접 비교 금지)
37.9%	sel_vs_inspect	예선 14:1
74.7%	sel_vs_inspect	APS 공식 50:1

경계 (★ 헤드라인)

경계	중앙값	IQR
운영 가드(검사율 90%)	56	[49.5, 68.5]
경제 교차(그리드, n=50)	54	[46.2, 77.8]
(참고) 경제 교차 닫힌해	52	n=38 검열
두 경계 상관	r = 0.12	순서 뒤집힘 26/50

역산

검사율	R 구간 (지지≥50%)
12%	[6.4, 7.1]
30%	[10.3, 13.6]
50%	[19.2, 24.7]
효율 정책 수	약 15개 (14~17) / APS 29개

공정 최적화

항목	값
손익분기 cl	16 (95% CI 하단>0 기준)
cl ≤ 15	대응 (CI 0 포함)
모델 최대 우위	cl≈22, 절대차 158
S59 최적 관리상한	21.8% (cl=15, nested)

디스플레이

항목	값
불변량	$cl_{max} + \gamma V = 52.0$ (12점)
Λ_{max}	49.4
β 관측/예측	48/52/58/70 vs 49.4/52.0/58.1/70.6
디스플레이 한 점	$\gamma 0.7 \cdot V_{20} \rightarrow 52 \rightarrow 38$ (−27%)

이상탐지

항목	값
지도 vs 비지도 AUC	0.725 vs 0.547
손익분기 정밀도	$(1+\mu)/(\Lambda+\mu) \text{ — } cl=15 \rightarrow 7.0\%$
항등식 확증	B 실측 6.4% vs 이론 7.02%

항목	값
순정보 (cl=15)	지도 +23.5%p / IForest +5.4%p / 무작위 <0

드리프트 / 전처리

항목	값
domain AUC	0.977 (PSI>0.2가 82/474)
유병률 Q1~Q4	6.6 / 11.2 / 5.1 / 3.6%
반사실 (Q4 R)	35 → 8.0
전처리 <code>np.var</code> vs <code>nanvar</code>	52센서 AUC 0.610 / 474센서 0.751
결측 신호 클러스터	6개 (BH-FDR q<0.10)
R ² (pAUC↔경계)	0.42

10. 우리가 스스로 철회한 것들 (★ 최대 자산)

#	철회한 주장	왜 틀렸나	어떻게 잡았나
1	"raw 실익 상한은 존재하지 않는다"	극단 구간 거동을 전역으로 확장	자기 표에 이미 반례
2	"min(가드,교차)만 안정적"	min 연산자의 기계적 산물	순열 대조 5,000회
3	"AUC가 경계를 예측한다 (단힘)"	n=66을 독립 취급 (유효 n=10)	클러스터 부트스트랩
4	"결측은 신호가 아니다"	관측과 다른 양 을 검정	센서별 지시자로 재검정 → 뒤집힘
5	"손익분기 cl = 17"	임의의 승률컷 75%가 만든 값	CI 기준으로 통일 → 16
6	"이상탐지 A vs B 8:8 무승부"	seed 종속 + 정보 없는 지점 동등 가중	표본 있는 지점만 → B 6:2
7	"결측 비용 순위 뒤바뀜 = AUC≠비용 증거"	AUC로도 구분 불가면 노이즈로 설명됨	대응검정 → 둘 다 무의
8	"효율 정책 정확히 15개"	해상도·허용오차 의존	그리드 스윕 → 14~17

추가로 임의 상수 3개를 발견해 제거:

그리고 실제 코드 버그 2건 발견 (6-6 참조).

“우리는 유리한 결과도 검정해서 기각했다.” 이 태도가 남은 결과들의 신뢰도를 만듭니다.

11. 한계 (정직하게)

한계	내용
인과 아님	SHAP·조건부 불량률은 관측 데이터의 상관. "S59가 원인"이 아니라 "S59를 먼저 점검하라". 산출물은 DOE 우선순위
미지 불량 실증 불가	SECOM의 모든 불량은 라벨에 있음 → 지도학습이 이미 다 봄
표본 한계	양성 104개. 경계·꼬리 통계는 seed에 크게 흔들림 → 단일 숫자 금지
비용비 가정	cl, cs, γ , V의 현실값은 산업별 실측 필요. 현재는 예시값
모델 가정	검출 불량률의 폐기 손실 미계상 / 홀드·재작업 지연 비용 없음 / 리페어 용량 무제한 / $\beta \cdot \alpha$ 는 임계값과 무관
일반화	SECOM + APS 2개. 커널은 데이터셋 독립이나 응용층은 SECOM 시연
센서 간 상관	관리한계선은 S59만 독립적으로 움직인다고 가정. 실제로는 다른 센서가 따라 움직임

12. 아이디어 8개 커버리지 & 발표 서사

커버리지

#	항목	완성도	핵심 결과
1	이진 분류	100%	AUC 0.731, 3난제(불균형·결측·고차원) 정면 대응
2	이상 탐지	90%	손익분기 = 1차모델 한계정밀도 항등식
3	피쳐 선택	95%	$K \approx 100$ 고원, 474→290
4	드리프트	85%	3성분 분해 + 입력감시≠재학습 트리거
5	결측 비교	90%	8종 동일 + 결측 자체가 신호 + NaN 버그

#	항목	완성도	핵심 결과
6	공정 최적화	90%	관리한계선 21.8%, 손익분기 $cl=16$
7	XAI	90%	S59 3중 검증 + 국소 워터폴
8	양상불·비용민감	100%	커널 + 역산 (층위가 다름)

평균 약 93%. 8/8 본선 수준.

발표 서사 — 기능 나열 ❌ 질문 사슬 ✔️

"불량을 예측한다"에서 시작해서 → 왜 그런가? (XAI) → 그래서 검사할까? (Cost Layer) → 비용비를 모르면? (역산) → 뭘 바꿔야 하나? (공정 최적화) → 모르는 불량은? (이상 탐지) → 시간이 지나면? (드리프트) → 다 감시해야 하나? (피쳐 선택) → 애초에 모델이 필요한가? (손익분기 $cl=16$)

헤드라인 후보 3개

1. "단일 숫자로 말할 수 없다" — 두 경계가 무상관($r=0.12$), 절반 확률로 뒤집힘
2. "비용비를 묻지 않는다" — 검사율 12% → $R [6.4, 7.1]$
3. "모델이 필요한 구간은 좁다" — $cl \in [16, 35]$. AI가 AI 불필요를 판정

마무리 문장

AUC 0.73은 약점이 아니라 논지 그 자체입니다.

- AUC 0.73 모델도 비용 구조를 제대로 놓으면 31% 절감
- 반대로 AUC 0.9 모델도 비용비를 잘못 알면 41.3% 손실
- 심지어 센서 1개로도 저비용 구간에서는 474모델과 대등

→ 모델 성능은 이 문제의 병목이 아니다.

13. 멘토링 질문 리스트

2시간 배분 제안: 설명 60분(커널·역산·손익분기 중심) / 빠른 훑기 30분 / 시연 15분 / 질문 15분
설명으로만 채우면 아깝습니다. 아래는 제3자만 답할 수 있는 것들입니다.

● 반드시 물어볼 것 (5개)

1. "모델이 필요 없다"는 결론이 AI 경진대회에서 위험한가?

우리 핵심 결과 중 하나가 **" $cl < 16$ 이면 474센서 모델 없이 센서 1개로 충분"**입니다. 기술적으로는 정직하고 강한 결론인데, AI 대회에서 "AI가 불필요하다"고 말하는 게 감점 요인일 수 있습니다.

- 그대로 내세워도 되는가?
- 아니면 **"모델의 가치를 비용으로 정량화했다"**로 프레임업을 바꿔야 하는가?

- 어느 쪽이 심사에서 유리한가?

2. 디스플레이 도메인 값 — cl , cs , γ , V 의 현실 범위

지금 전부 가정값입니다. 실무자 감각이 필요합니다.

- 패널 폐기 손실 $\div$ 검사 단가 $\approx$ 얼마?
- 유출 손실(고객 클레임 포함) $\div$ 검사 단가 $\approx$ 얼마?
- 레이저 리페어 성공률(γ) — 결함 유형별로 대략?
- 리페어 회수가치(V) — 검사 단가 대비 몇 배?

→ 하나만 현실값이 나와도 *******"우리 도구가 실제 디스플레이 좌표에서 뭐라고 답하는가"*******를 발표에 넣을 수 있습니다.

3. 22라운드치 중 뭘 버려야 하는가

발표는 압축이 관건인데, 저희는 계속 추가만 해서 판단이 편향돼 있습니다.

- 8개 항목을 다 보여줄지, 3~4개만 깊게 갈지
- 커널의 대수 유도(λ_{μ} 붕괴, 항등식)를 어디까지 보여줄지 — **수식이 강점인가 부담인가**
- 검증 이야기(4중 검증, 버그 2건)를 얼마나 할지

4. 정직성 노출 수위

자기 결과 8건을 스스로 철회했고, 코드 버그 2건을 발견했습니다.

- 이걸 발표에 넣으면 "엄밀하다"로 읽히는가, **"결국 안 됐다"**로 읽히는가?
- 넣는다면 앞인가 뒤인가?
- 우리는 "정직성이 신뢰를 만든다"고 봤는데, 심사 현장에서도 그런가?

5. 실무 적용 가능성 — 이 도구를 실제로 쓸 수 있나

- 펍에서 *******"현재 검사율"*******을 이 도구에 넣을 수 있는 형태로 알고 있는가?
- ****역산 결과("귀사는 유출을 검사비의 X배로 평가하는 셈")****를 현업이 실제로 유용하다고 느낄까?
- 도입하려면 무엇이 더 필요한가?

● 시간 되면 물어볼 것

6. **디스플레이 연결을 더 강화할 방법** — SECOM이 반도체인 건 주최측 제공이라 어쩔 수 없는 데, 해석·용어·비용 모델에서 더 연결할 지점이 있는지 (마더글라스 단위 판정, 셀/모듈 공정 구분 등)
7. **드리프트 실무 권고의 타당성** — "입력 감시만으로 재학습 판단하면 오경보"가 현장 경험과 맞는지. 실제로 PSI 모니터링을 트리거로 쓰는 곳이 많은지
8. **경계의 seed 분산을 어떻게 전달할지** — "단일 숫자로 말할 수 없다"가 우리 헤드라인인데, 청중이 "그래서 답이 뭔데요?"로 받을 위험. 구간으로 제시하는 게 성숙함으로 읽힐지 모호함으

로 읽힐지

9. **시뮬레이터 시연 동선** — 4탭 중 어느 순서로, 몇 분 쓸지. 슬라이더를 심사위원이 직접 만지게 할지
10. **What-if 기능을 추가할 가치가 있는지** — "이 센서를 바꾸면 예측이 어떻게 변하나"(사전 조치). 프로젝트명이 "시뮬레이터"인데 지금은 조건을 바꿔보는 기능이 없음. 1시간이면 되는데 우선순위가 높은지

● 발표 형식 확인 (사무적)

- 발표 시간 (10/15/20분에 따라 구조가 완전히 달라짐)
- 시연 시간이 발표 시간에 포함되는지
- 질의응답 유무·시간
- 장비 — 본인 노트북 사용 가능한지, 해상도, 인터넷 필요 여부
- 심사 기준 배점 — 기술 깊이 / 실용성 / 완성도 / 발표력의 비중
- 제출물 형식 (슬라이드만? 코드? 보고서?)

준비 팁

- 방어 자료는 준비하되 먼저 꺼내지 마세요. 멘토가 "이거 검증했나요?"라고 물으면 그때 KEY_NUMBERS를 펴는 게, 처음부터 검증 얘기를 늘어놓는 것보다 인상이 좋습니다
- 멘토 피드백이 계획을 바꿉니다. "이건 빼고 저걸 키워라"가 나오면 남은 3.5일 우선순위가 통째로 달라집니다. 멘토링 전에 새 실험을 시작하지 마세요

부록 — 현재 완성도

영역	비중	완성도
분석·기술	50%	99%
산출물(시뮬레이터)	25%	88%
서사·프레이밍	5%	85%
전달(발표)	20%	10% ← 유일한 실질 리스크
종합		≈ 89%

남은 11%는 거의 전부 발표입니다. 화요일 초안 하나로 95%까지 갑니다.